

ChIP-seq дз (на четырёх стадиях)

Шорина Анна

26 сентября 2026 г.

1 Что вообще делаем

В семинарском отчете был ChIP-seq Foxd3 для стадии 14 somite stage (14ss); отдельно был готовый пример для стадии 5-6 somite stage (5-6ss). Здесь делаем то же самое для двух оставшихся стадий, 75 % epiboly (75ep) и 1-2 somite stage (1-2ss). Затем сводим все четыре стадии в одну картину и смотрим, как меняется связывание Foxd3 на пути от гаструляции к миграции клеток нервного гребня:

75ep → 1-2ss → 5-6ss → 14ss.

2 Анализ стадии 75 % epiboly

```
samtools flagstat data/75ep/foxd3_75ep_chip.nuclear.bam
samtools flagstat data/75ep/foxd3_75ep_input.nuclear.bam

bamCoverage -b data/75ep/foxd3_75ep_chip.nuclear.bam \
-o results/signal/foxd3_75ep_chip.CPM.bw \
-normalizeUsing CPM -binSize 10 -numberOfProcessors 4
bamCoverage -b data/75ep/foxd3_75ep_input.nuclear.bam \
-o results/signal/foxd3_75ep_input.CPM.bw \
-normalizeUsing CPM -binSize 10 -numberOfProcessors 4

bigwigCompare -b1 results/signal/foxd3_75ep_chip.CPM.bw \
-b2 results/signal/foxd3_75ep_input.CPM.bw \
-operation log2 -pseudocount 1 -binSize 10 \
-o results/signal/foxd3_75ep.log2_IP_Input.bw

macs3 callpeak -t data/75ep/foxd3_75ep_chip.nuclear.bam \
-c data/75ep/foxd3_75ep_input.nuclear.bam \
-f BAMPE -g 1360000000 -n foxd3_75ep -q 0.01 -outdir results/peaks
```

- ChIP: 23 863 894 alignments; Input: 39 931 858 alignments; оба BAM без дубликатов, 100 % properly paired

- 36 пиков
- FRiP = $4101/23\,863\,894 \approx 0,017\%$
- Самый значимый пик: NC_007113.7:33 276 014-33 276 551, signalValue = 21,70, $-\log_{10}(p) = 109,26$, $-\log_{10}(q) = 100,05$ ($q \approx 8,9 \times 10^{-101}$)

```
computeMatrix reference-point -referencePoint center \
-R results/peaks/foxd3_75ep_summits.bed \
-S results/signal/foxd3_75ep_chip.CPM.bw \
  results/signal/foxd3_75ep_input.CPM.bw \
-b 2000 -a 2000 -binSize 20 -o results/figures/foxd3_75ep.matrix.gz

plotHeatmap -m results/figures/foxd3_75ep.matrix.gz \
-out results/figures/foxd3_75ep.heatmap.pdf \
-samplesLabel "Foxd3 ChIP" "Input" -refPointLabel "summit"
plotProfile -m results/figures/foxd3_75ep.matrix.gz \
-out results/figures/foxd3_75ep.profile.pdf \
-samplesLabel "Foxd3 ChIP" "Input" -refPointLabel "summit"
```




Рис. 1: 75ер: средний сигнал ChIP и Input вокруг summit




Рис. 2: 75ер: сигнал по каждому из 36 пиков

Вообще на heatmap видно, что у верхних строк Input такой же выраженный сигнал в центре, как и у ChIP. Возможно, это участки с общим повышенным фоном (повторы, области с высокой доступностью хроматина в принципе).

3 Анализ стадии 1-2 somite stage

Команды такие же как в предыдущем разделе (только имя стадии меняем на 1-2ss).

- ChIP: 12 816 614 alignments; Input: 33 460 348 alignments; без дубликатов, 100 % properly paired
- 40 пиков
- FRiP = $1799/12\,816\,614 \approx 0,014\%$
- Самый значимый пик: NC_007113.7:33 276 062-33 276 596, signalValue = 21,23, $-\log_{10}(p) = 65,27$, $-\log_{10}(q) = 56,18$ ($q \approx 6,6 \times 10^{-57}$)

Тут самый значимый пик 1-2ss лежит практически в тех же координатах, что для 75ер (сдвиг всего на несколько десятков п.н.), так что наверное это один и тот же локус.




Рис. 3: 1-2ss: средний сигнал ChIP и Input вокруг summit




Рис. 4: 1-2ss: сигнал по каждому из 40 пиков

Тут то же самое в верхней части heatmap Input - видимо, часть самых ярких пиков обусловлена фоном, а не только специфичным связыванием.

4 Сравнение четырёх стадий

Таблица 1: Основные метрики по всем четырём стадиям

Стадия	ChIP align.	Input align.	Пиков	FRiP	$\max - \log_{10}(q)$
75ep	23 863 894	39 931 858	36	0,017 %	100,05
1-2ss	12 816 614	33 460 348	40	0,014 %	56,18
5-6ss	18 853 396	н/д*	839	0,236 %	163,70
14ss	41 553 880	27 794 668	170	0,162 %	321,45




Рис. 5: Heatmap сигнала ChIP/Input вокруг summit для всех четырёх стадий

Число пиков: $36 \rightarrow 40 \rightarrow 839 \rightarrow 170$. FRiP минимален на ранних стадиях (0,014-0,017 %), потом выходит на максимум на 5-6ss (0,236 %) и потом падает к 14ss (0,162 %). Наибольший по абсолютному числу пиков набор - у 5-6ss, самый выраженный по силе enrichment отдельный пик - у 14ss ($-\log_{10}(q) = 321,45$).

Число пиков зависит не только от глубины секвенирования. Например, у 5-6ss всего 18,9 млн ридов, но больше всего пиков, а у 14ss — 41,6 млн ридов, но в 5 раз меньше пиков. Поэтому число пиков нельзя напрямую считать показателем активности Foxd3.

5 Попарное сравнение наборов пиков

Для каждой пары стадий отсортированные BED-файлы пиков сравнивались через `bedtools intersect` (число общих и специфичных интервалов) и `bedtools jaccard` (доля перекрывающихся оснований):

```
sort -k1,1 -k2,2n results/peaks/foxd3_<stage>_peaks.narrowPeak > <stage>.bed

bedtools intersect -a A.bed -b B.bed -u | wc -l    # A,    B
bedtools intersect -a A.bed -b B.bed -v | wc -l    # ,    A
bedtools jaccard   -a A.bed -b B.bed              #
```

Таблица 2: Все шесть попарных сравнений

A	B	Peaks A	Peaks B	$A \cap B$	Специфично для A	Jaccard
75ep	1-2ss	36	40	12	24	0,174
75ep	5-6ss	36	839	22	14	0,023
75ep	14ss	36	170	18	18	0,075
1-2ss	5-6ss	40	839	30	10	0,028
1-2ss	14ss	40	170	12	28	0,043
5-6ss	14ss	839	170	40	799	0,037

Наиболее похожи по расположению пиков соседние ранние стадии **75ep** и **1-2ss** (Jaccard 0,174; 12 из 36 пиков 75ep уже присутствуют на 1-2ss). Наиболее различаются **75ep** и **5-6ss** (Jaccard 0,023) - за время между гастрულიцией и спецификацией нервного гребня набор связанных участков примерно обновляется. Индекс Жаккара везде маленький (не превышает 0,2), что говорит об изменении связывания на каждом из переходов между стадиями.

Но вообще, низкий Jaccard между 5-6ss и 14ss (0,037) не означает, что почти все сайты 5-6ss исчезают биологически. `bedtools jaccard` считает долю общих оснований, а не долю общих пиков, поэтому при 839 пиках на одной стадии и 170 на другой даже полное включение меньшего набора в больший даёт невысокий Jaccard.

6 Форматы файлов

В файле на сервере написано явно указать функции файлов:

Формат	Что хранит	Text/Binary	Роль в этом анализе
FASTA (.fa)	Нуклеотидная последовательность референсного генома GRCz11	Text	Основа для выравнивания ридов и референс-дорожка в IGV
GTF	Координаты генов, транскриптов и экзонов	Text	Аннотация генов в IGV, привязка пиков к ближайшим генам
BAM	Выровненные на геном риды (координаты, CIGAR, флаги парности)	Binary	Вход всего пайплайна: <code>flagstat</code> , <code>bamCoverage</code> , <code>macs3 callpeak</code>
BAI	Индекс к BAM для быстрого произвольного доступа по координатам	Binary	Требуется <code>bamCoverage</code> и IGV для быстрой навигации по BAM
BigWig (.bw)	Непрерывный количественный сигнал (покрытие) по бинам генома	Binary	CPM-сигнал ChIP/Input и $\log_2(\text{ChIP/Input})$ для визуализации в IGV
BED	Геномные интервалы <code>chrom/start/end</code> (+ доп. поля)	Text	Summit-файлы, результаты <code>bedtools intersect</code> между стадиями
narrowPeak	BED6+4: интервалы пиков MACS3 с <code>signalValue</code> , $-\log_{10}(p)$, $-\log_{10}(q)$ и положением summit	Text	Главный результат peak calling, вход для FRiP, сравнения стадий и IGV
peaks.xls	Пики MACS3 плюс метаданные запуска (параметры, статистика фрагментов)	Text	Подробный протокол вызова пиков, дублирует narrowPeak в текстовом виде
TSV	Табличные данные с разделителем-табуляцией	Text	<code>frip_<stage>.tsv</code> , сводная таблица метрик по стадиям
matrix.gz	Матрица сигнала (пики $\times$ позиции вокруг summit), сжатая	Binary	Промежуточный результат <code>computeMatrix</code> , вход для heatmap/profile
PDF	Векторный документ (в этом анализе – готовые графики)	Binary	Результат <code>plotHeatmap/plotProfile</code> , а также сам итоговый отчёт

Если короче: BAM - это исходные выравнивания, BigWig - построенный из них непрерывный количественный сигнал по всему геному, а narrowPeak - уже список обогащённых участков, прошедших статистический порог значимости. BigWig не хранит отдельные риды, narrowPeak не хранит форму сигнала вне пика.

7 Визуализация в IGV

Во всех трёх локусах загружены референс GRCz11.fa, аннотация GRCz11.gtf, CPM-дорожки ChIP, $\log_2(\text{ChIP}/\text{Input})$ и narrowPeak для всех четырёх стадий; для дорожек ChIP выставлен единый масштаб (deepTools/IGV group autoscale), чтобы силу обогащения можно было сравнивать между стадиями напрямую.

7.1 Локус 1. Сильный пик 5-6ss

Координаты: NC_007117.7:32 206 483-32 207 024 (foxd3_5-6ss_chip_peak_211, самый значимый пик стадии).




Рис. 6: Локус 1, окно 32 204 000-32 209 500: ChIP, Input, $\log_2(\text{ChIP}/\text{Input})$ и вызванный пик 5-6ss




Рис. 7: Тот же локус в окне 32 100 000-32 320 000 (220 kb) с генами GRCz11.gtf

Пик стоит точно на вершине ChIP-сигнала при плоском Input. В узком окне (5,5 kb) генов нет; в широком окне (220 kb) видно, что ближайшие аннотированные гены находятся в десятках килобаз от пика в обе стороны. Так что это кандидат явно не в промотор конкретного гена.

7.2 Локус 2. Участок, связанный на нескольких стадиях

Координаты: NC_007113.7:33 276 014-33 276 551 - самый значимый пик 75ep и 1-2ss, тот же самый локус, что фигурирует и в пиках 5-6ss (foxd3_5-6ss_chip_peak_63) и 14ss (foxd3_14ss_peak_8).




Рис. 8: Локус 2, окно 33 273 500-33 279 000: пик присутствует на всех четырёх стадиях, шкала ChIP общая (на картинке видно, что выделено красным)

Тут видно, что enrichment на этом локусе разный у стадий: максимум на 5-6ss, потом ниже на 75ep и 1-2ss и минимален (хотя пик всё равно формально вызван) на 14ss.

7.3 Локус 3. Stage-specific участок

Координаты: NC_007112.7:259 734-260 218 (foxd3_5-6ss_chip_peak_1).




Рис. 9: Локус 3, окно 257 200-262 700: пик вызван только на 5-6ss

Пик вызван только на стадии 5-6ss и расположен у 5'-конца гена *cenpe*. На дорожках $\log_2(\text{ChIP}/\text{Input})$ для 75bp и 1-2ss в этом же месте виден слабый локальный подъём сигнала, который просто не преодолевает порог значимости MACS3. Поэтому отсутствие вызванного пика на другой стадии - это про порог детекции конкретного алгоритма, а не про то, что Foxd3 там вообще не связывается, так как слабое связывание может присутствовать, оставаясь статистически незначимым при данной глубине секвенирования.

8 Биологическая интерпретация

1. **Остаётся ли binding landscape постоянным?** Нет, и число пиков, и их расположение (индекс Жаккара $\leq 0,17$ для всех пар стадий), и сила enrichment существенно меняются на каждом из трёх переходов между стадиями.
2. **Стадия с самым выраженным ChIP-сигналом.** По абсолютному числу пиков и FRiP лидирует 5-6ss (839 пиков, FRiP 0,236 %); по силе самого значимого отдельного пика это 14ss ($-\log_{10}(q) = 321,45$).
3. **Стабильные между стадиями участки.** Локус 2 (NC_007113.7 около 33,276 Mb) вызывается на всех четырёх стадиях и, видимо, является устойчивым сайтом связывания с колеблющейся интенсивностью.
4. **Появляющиеся/исчезающие участки.** Подавляющее большинство пиков специфично для одной стадии (например, 799 из 839 пиков 5-6ss не пересекаются с 14ss) - локус 3 иллюстрирует такой stage-specific сайт.
5. **Почему ChIP-seq сам по себе не доказывает регуляцию.** ChIP-seq показывает только физический факт связывания белка с ДНК в данной точке генома, но не то, активирует Foxd3 транскрипцию или подавляет её. А ещё ближайший ген не обязательно является мишенью - энхансер может регулировать ген далеко от места связывания (как в локусе 1).
6. **Какие данные нужны, чтобы проверить функциональный эффект.** Из этой же статьи: ATAC-seq - показывает, меняется ли доступность хроматина в местах связывания Foxd3 при потере белка; H3K27ac ChIP-seq - маркирует активные энхансеры и промоторы, дает понять, активен ли регуляторный элемент под пиком; RNA-seq - показывает, меняется ли экспрессия ближайших генов-мишеней в *foxd3 mutant* по сравнению с контролем.

9 Итоговый вывод

Геномный binding landscape Foxd3 перестраивается от гаструляции к миграции нервного гребня так: набор связанных участков расширяется к стадии спецификации (5-6ss, максимум пиков и FRiP) и затем сужается к стадии миграции (14ss, где остаётся меньшее, но статистически наиболее значимое ядро сайтов). Часть этого можно считать биологической - в первую очередь сам факт роста и сокращения набора пиков, который

не объясняется различиями в глубине секвенирования (у стадии с максимумом пиков библиотека, наоборот, самая мелкая). Но при этом абсолютные числа пиков, точные значения FRiP и результаты попарных сравнений чувствительны к порогу q , качеству и глубине Input и особенностям картируемости конкретных участков генома, так что их стоит воспринимать как ориентир только. Отделить связывание от регуляции по одному ChIP-seq нельзя, для этого нужны дополнительные данные ATAC-seq, H3K27ac ChIP-seq и RNA-seq.

Приложение: использованные команды

```
# QC
samtools flagstat data/<stage>/foxd3_<stage>_chip.nuclear.bam
samtools flagstat data/<stage>/foxd3_<stage>_input.nuclear.bam

#
bamCoverage -b <BAM> -o <CPM.bw> -normalizeUsing CPM -binSize 10 -
    numberOfProcessors 4
bigwigCompare -b1 <chip.CPM.bw> -b2 <input.CPM.bw> -operation log2 \
    -pseudocount 1 -binSize 10 -o <log2.bw>

# peak calling
macs3 callpeak -t <chip.bam> -c <input.bam> -f BAMPE -g 1360000000 \
    -n foxd3_<stage> -q 0.01 -outdir results/peaks

# FRiP
samtools view -c <chip.bam>
samtools view -c -L <peaks.narrowPeak> <chip.bam>

# heatmap/profile
computeMatrix reference-point -referencePoint center -R <summits.bed> \
    -S <chip.CPM.bw> <input.CPM.bw> -b 2000 -a 2000 -binSize 20 -o <matrix.gz>
plotHeatmap -m <matrix.gz> -out <heatmap.pdf> -samplesLabel "Foxd3 ChIP" "Input" \
    -refPointLabel "summit"
plotProfile -m <matrix.gz> -out <profile.pdf> -samplesLabel "Foxd3 ChIP" "Input" \
    -refPointLabel "summit"

#
sort -k1,1 -k2,2n <peaks.narrowPeak> > <stage>.bed
bedtools intersect -a A.bed -b B.bed -u | wc -l
bedtools intersect -a A.bed -b B.bed -v | wc -l
bedtools jaccard -a A.bed -b B.bed
```