

ChIP-seq семинар

Шорина Анна

26 сентября 2026 г.

1 Что вообще делаем

Foxd3 - транскрипционный фактор, который на ранних стадиях выступает как пионер-фактор, открывает хроматин для программы нервного гребня. Потом переключается на роль репрессора, сдерживает миграцию и дифференцировку клеток. Основной набор секвенирования (bioChIP-seq Foxd3 у *Danio rerio*, сборка генома GRCz11) опубликован как GEO GSE106676.

Надо пройти полный ChIP-seq пайплайн от BAM-файлов до вызванных пиков и оценки качества на одной стадии развития, 14 somite stage (14ss). Потом надо сопоставить результат с готовым примером для стадии 5-6 somite stage (5-6ss).

Входные данные - уже выровненные и отфильтрованные BAM-файлы ChIP и Input для Foxd3 на стадии 14ss (foxd3_14ss_chip.nuclear.bam, foxd3_14ss_input.nuclear.bam), референс GRCz11 и conda-окружение с samtools, deepTools, MACS3, bedtools.

В отчете написаны таблички в латехе (а не скриншоты), так как сервер постоянно вылетал, и мне пришлось сохранять выводы команд в блокноте ctrl-C, ctrl-V с терминала.

2 Контроль качества выравниваний

Для обоих BAM-файлов было получено samtools flagstat:

```
samtools flagstat data/foxd3_14ss_chip.nuclear.bam
samtools flagstat data/foxd3_14ss_input.nuclear.bam
```

Таблица 1: Статистика выравниваний ChIP и Input (14ss)

	ChIP	Input
Всего alignments	41 553 880	27 794 668
Пар ридов	20 776 940	13 897 334
Картировано	100 %	100 %
Properly paired	100 %	100 %
Дубликаты	0	0

В обоих случаях дубликатов и вторичных выравниваний нет, все риды картированы и корректно спарены. Единственное, отличается глубина, ChIP примерно в 1,5 раза глубже Input. Это значит, что напрямую сравнивать количество ридов между дорожками нельзя, надо нормировать на глубину библиотеки.

3 Построение нормализованных сигнальных дорожек

Покрытие BAM в непрерывный сигнал переводится инструментом `bamCoverage` с нормировкой CPM и окном 10 п.н.:

```
bamCoverage -b data/foxd3_14ss_chip.nuclear.bam \
-o results/signal/foxd3_14ss_chip.CPM.bw \
-normalizeUsing CPM -binSize 10 -numberOfProcessors 4

bamCoverage -b data/foxd3_14ss_input.nuclear.bam \
-o results/signal/foxd3_14ss_input.CPM.bw \
-normalizeUsing CPM -binSize 10 -numberOfProcessors 4
```

Далее из двух CPM-дорожек строится дорожка обогащения:

```
bigwigCompare -b1 results/signal/foxd3_14ss_chip.CPM.bw \
-b2 results/signal/foxd3_14ss_input.CPM.bw \
-operation log2 -pseudocount 1 -binSize 10 \
-o results/signal/foxd3_14ss.log2_IP_Input.bw
```

Для каждого бина x вычисляется

$$S(x) = \log_2 \left(\frac{\text{ChIP}(x) + 1}{\text{Input}(x) + 1} \right).$$

Тут +1 устраняет деление на ноль в пустых бинах. Положительные значения $S(x)$ означают, что ChIP-сигнал выше Input, отрицательные наоборот.

4 Пик-коллинг MACS3

```
macs3 callpeak -t data/foxd3_14ss_chip.nuclear.bam \
-c data/foxd3_14ss_input.nuclear.bam \
-f BAMPE -g 1360000000 -n foxd3_14ss -q 0.01 \
-outdir results/peaks
```

MACS3 сравнивает наблюдаемое покрытие ChIP с ожидаемым локальным фоном, который оценивается из Input, и отбирает участки, где отклонение стат значимо после поправки на множественное тестирование (Benjamini-Hochberg, $q < 0,01$).

Основной результат - `foxd3_14ss_peaks.narrowPeak`, формат BED6+4:

Таблица 2: Колонки narrowPeak

#	Значение
1-3	chrom, start, end - координаты пика
4	name - идентификатор пика
5	score - целочисленный score для браузера генома
6	strand (не определяется, всегда .)
7	signalValue - fold-enrichment в summit
8	$-\log_{10}(p)$
9	$-\log_{10}(q)$
10	положение summit относительно начала пика

```
wc -l results/peaks/foxd3_14ss_peaks.narrowPeak
# 170
```

Найдено 170 пиков. Но число пиков нельзя приравнять к числу сайтов связывания Foxd3, так как часть настоящих сайтов не проходит порог значимости, а расположенные рядом сайты MACS3 может объединить в один пик.

Сортировка по значимости:

```
sort -k9,9nr results/peaks/foxd3_14ss_peaks.narrowPeak | head
```

Самый значимый пик - foxd3_14ss_peak_74 (NC_007126.7:35 583 506-35 583 991), signalValue = 25,00, $-\log_{10}(p) = 330,35$, $-\log_{10}(q) = 321,45$, то есть $q \approx 3,5 \times 10^{-322}$. Самый значимый пик не совпадает с пиком максимального fold-enrichment (peak_9, signalValue = 34,67).

5 FRiP

```
samtools view -c data/foxd3_14ss_chip.nuclear.bam
# 41553880

samtools view -c -L results/peaks/foxd3_14ss_peaks.narrowPeak \
  data/foxd3_14ss_chip.nuclear.bam
# 67346
```

$$\text{FRiP} = \frac{67\,346}{41\,553\,880} \approx 0,00162 \text{ (0,162 \%)}.$$

Значение маленькое, так как 170 узких пиков не могут собрать заметную долю ридов такой глубокой библиотеки на геноме размером $\sim 1,4$ млрд п.н.

6 Сигнал вокруг summit

```

computeMatrix reference-point -referencePoint center \
-R results/peaks/foxd3_14ss_summits.bed \
-S results/signal/foxd3_14ss_chip.CPM.bw \
  results/signal/foxd3_14ss_input.CPM.bw \
-b 2000 -a 2000 -binSize 20 \
-o results/figures/foxd3_14ss.matrix.gz

plotHeatmap -m results/figures/foxd3_14ss.matrix.gz \
-out results/figures/foxd3_14ss.heatmap.pdf \
-samplesLabel "Foxd3 ChIP" "Input" -refPointLabel "summit"

plotProfile -m results/figures/foxd3_14ss.matrix.gz \
-out results/figures/foxd3_14ss.profile.pdf \
-samplesLabel "Foxd3 ChIP" "Input" -refPointLabel "summit"

```

В матрице `foxd3_14ss.matrix.gz` каждая строка соответствует одному вызванному пику (окно ± 2 kb вокруг его summit), а столбцы бинам по 20 п.н.; значения в ячейках - CPM-сигнал, отдельно для ChIP и Input. Heatmap визуализирует эту таблицу построчно, profile - усредняет её по всем пикам.






Рис. 1: Средний сигнал ChIP и Input около summit пиков, 14ss



На профиле у ChIP виден острый узкий пик точно в положении summit, а Input остаётся более плоским. Это как раз критерий специфичного связывания Foxd3

7 Сопоставление с 5-6ss

```
bedtools intersect -a teacher/foxd3_5-6ss_peaks.narrowPeak \
-b results/peaks/foxd3_14ss_peaks.narrowPeak -u \
> results/stage_comparison/shared_5-6ss_14ss.bed

bedtools intersect -a results/peaks/foxd3_14ss_peaks.narrowPeak \
-b teacher/foxd3_5-6ss_peaks.narrowPeak -v \
> results/stage_comparison/only_14ss.bed
```

Таблица 3: Сравнение стадий 5-6ss и 14ss

	5-6ss	14ss
ChIP alignments	18 853 396	41 553 880
Пиков	839	170
FRiP	0,236 %	0,162 %
Общих пиков	40	
Специфичных для 14ss	130 (из 170)	

40 из 839 пиков стадии 5-6ss (около 5 %) сохраняются к стадии 14ss, а 130 из 170 пиков 14ss (76 %) уникальны. При этом библиотека 5-6ss заметно мельче (18,9 млн против 41,6 млн ридов у 14ss), а число пиков на ней в 5 раз больше, то есть такое падение числа пиков к 14ss нельзя объяснить глубиной секвенирования, и оно выглядит как биологическое сужение связывания при переходе к миграции нервного гребня.

8 Итого

Пайплайн BAM QC - CPM BigWig - log2(ChIP/Input) - MACS3 peak calling - FRiP - heatmap/profile сделан для стадии 14ss по презенташке с семинара (все команды оттуда кроме mamba на conda при создании окружения). Получено 170 значимых пиков Foxd3, качество обогащения подтверждается контрастом ChIP/Input на profile и heatmap. Сравнение с 5-6ss показывает сокращение набора связанных участков к стадии миграции.