

Отчёт по ДЗ. Метагеномика, данные soil

Шорина Анна

20 сентября 2026 г.

Что за данные

Образцы почвы разложили по закрытым ёмкостям и залили керосином в трёх вариантах: k0 (контроль, без керосина), k5 (5 г/кг) и k25 (25 г/кг). Дальше из каждой ёмкости брали пробы в четыре момента времени: день 3 (t1), день 90 (t2), день 180 (t3) и день 360 (t4). На каждую точку по три реплики, итого $3 \times 4 \times 3 = 36$ образцов.

Секвенировали участок V4-V5 гена 16S rRNA праймерами 515F и 907R, Illumina MiSeq, парноконцевое чтение по 250 нт.

Обработка: QIIME 2 2024.10 в контейнере `quay.io/qiime2/amplicon:2024.10`. Тяжёлые шаги (DADA2, классификация, дерево) через SLURM.

Задача 1. FastQC

```
fastqc -o fastqc $SOIL/raw_reads/SRR17307316_1.fastq
```



Basic Statistics

Measure	Value
Filename	SRR17307316_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	10833
Total Bases	2.7 Mbp
Sequences flagged as poor quality	0
Sequence length	251
%GC	57

Рис. 1: Basic Statistics для образца SRR17307316

В образце 10 833 прочтения, длина 251 нт, GC 57 процентов; прочтений, помеченных как некачественные, нет вообще.




Рис. 2: Per base sequence quality




Рис. 3: Per sequence quality scores

Медиана держится в зелёной зоне по всей длине прочтения. Просаживается только нижний хвост распределения, если смотреть на сводку по всем образцам, 9-й перцентиль падает с 37 в районе 50-й позиции до 20 на 250-й.




Рис. 4: Per base sequence content. Первые позиции живут своей жизнью

Три модуля FastQC показывают красный крестик (а не зеленую галочку): Per base sequence content, Sequence Duplication Levels и Overrepresented sequences. FastQC рассчитан на полногеномное секвенирование, где прочтения случайно раскиданы по геному, и ждёт равномерного нуклеотидного состава. У нас же все прочтения покрывают один и тот же участок 16S, так что и дубликаты, и оверпредставленные последовательности - это нормально.

Из прикольного - есть неровные полосы в первых примерно 25 позициях на Per base sequence content, поэтому:

Задача 2. Зачем `--p-trim-left 25`

Первые 25 нт прочтения - это последовательность праймера 515F (19 нт) плюс линкер. Почему режем:

Во-первых, эта часть прочтения вообще не из генома бактерии. Её задал синтетический олигонуклеотид, а в вырожденных позициях (M в 515F) буква определяется тем, какая именно молекула праймера села на матрицу. DADA2 работает с точностью до одного нуклеотида, так что он честно разложил бы один и тот же организм на несколько разных ASV.

Во-вторых, первые циклы Illumina дают смещённый нуклеотидный состав и не самые надёжные оценки качества, это вот и видно на графике Per base sequence content.

Импорт и качество по всем образцам

```
qiime tools import \
  --type 'SampleData[SequencesWithQuality]' \
  --input-path soil_manifest.tsv \
  --output-path qza/soil_reads.qza \
  --input-format SingleEndFastqManifestPhred33V2

qiime demux summarize \
  --i-data qza/soil_reads.qza \
  --o-visualization qzv/soil_reads.qzv
```




Рис. 5: Качество прямых прочтений по всем 36 образцам

forward reads	
Minimum	5128
Median	15852.0
Mean	17815.611111
Maximum	45492
Total	641362

Рис. 6: Число прочтений по образцам

Всего 641 362 прочтения на 36 образцов. Минимум 5128, медиана 15 852, максимум 45 492. Разброс почти в девять раз - это заметно неровнее, чем хотелось бы, и поэтому дальше понадобится разрежение.

DADA2

```
qiime dada2 denoise-single \  
  --i-demultiplexed-seqs qza/soil_reads.qza \  
  --p-trim-left 25 \  
  --p-trunc-len 200 \  
  --p-max-ee 3 \  
  --p-n-threads 20 \  
  --p-pooling-method "pseudo" \  
  --p-chimera-method "consensus" \  
  --p-min-fold-parent-over-abundance 4 \  
  --o-table qza/soil_ASV_table.qza \  
  --o-representative-sequences qza/soil_rep_seq.qza \  
  --o-denoising-stats qza/soil_reads.dada2.stats.qza
```

Задача 3. Сколько прочтений выжило

```
qiime metadata tabulate \  
  --m-input-file qza/soil_reads.dada2.stats.qza \  
  --o-visualization qzv/soil_reads.dada2.stats.qzv
```

Этап	Сумма	Минимум	Медиана	Максимум
input	641 362	5128	15 852	45 492
filtered	638 869	5087	15 799	45 407
denoised	622 542	4830	15 305	44 292
non-chimeric	608 362	4809	14 908	43 518

Доля выживших прочтений: 94,9 процента. По отдельным образцам от 89,4 до 97,1 процента, медиана 95,1.

Самый большой образец - SRR17307475, 43 518 прочтений после всех фильтров.
Самый маленький - SRR17307380, 4809 прочтений.

Что это говорит о качестве данных Фильтр по качеству забирает совсем немного: медиана passed filter 99,6 процента, минимум 97,9. Основные потери приходятся на денойзинг и удаление химер, и они тоже маленькие.

Что немного напрягает - неравномерность глубины. Между самым большим и самым маленьким образцом разница в девять раз...

sample-id #id-type	Input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	non- ohimerio numeric	percentage of input non- ohimerio numeric
SRR17307258	26992	26932	99.78	26472	25395	94.08
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307269	10387	10322	99.37	9859	9859	94.92
SRR17307273	23451	23405	99.8	23023	20966	89.4
SRR17307278	24834	24783	99.79	24230	23607	95.06
SRR17307316	10833	10723	98.98	10193	10189	94.06
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307392	25424	25374	99.8	24617	24547	96.55
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307406	22460	22420	99.82	21987	21190	94.35
SRR17307409	29485	29434	99.83	28819	28088	95.26
SRR17307413	9875	9740	98.63	9595	9532	96.53
SRR17307419	24624	24574	99.8	23982	23904	97.08
SRR17307420	9962	9873	99.11	9453	9441	94.77
SRR17307436	9471	9380	99.04	9019	8993	94.95
SRR17307475	45492	45407	99.81	44292	43518	95.66
SRR17307492	22781	22731	99.78	22069	21888	96.08
SRR17307525	31085	31013	99.77	30414	29356	94.44
SRR17307527	7624	7536	98.85	7335	7291	95.63
SRR17307530	21513	21471	99.8	21122	20436	94.99
SRR17307534	26187	26156	99.88	25689	25194	96.21
SRR17307540	9247	9056	97.93	8949	8918	96.44
SRR17307546	9539	9471	99.29	9119	9115	95.56
SRR17307551	18317	18289	99.85	17853	17069	93.19
SRR17307593	5208	5159	99.06	4887	4866	93.43
SRR17307610	27416	27359	99.79	26566	26518	96.72
SRR17307628	13387	13310	99.42	12757	12747	95.22
SRR17307630	29957	29912	99.85	29473	27473	91.71
SRR17307632	28399	28342	99.8	27799	26936	94.85
SRR17307636	6890	6812	98.87	6642	6634	96.28
SRR17307643	8233	8174	99.28	7711	7705	93.59
SRR17307647	24317	24279	99.84	23851	22499	92.52
SRR17307649	9577	9502	99.22	9121	9114	95.17
SRR17307666	30483	30410	99.76	29495	29346	96.27

Рис. 7: Статистика фильтрации DADA2 по образцам

Таблица ASV

```
qiime feature-table summarize \  
  --i-table qza/soil_ASV_table.qza \  
  --o-visualization qzv/soil_ASV_table.qzv \  
  --m-sample-metadata-file soil_metadata_full.tsv
```

Summary Statistic	Value
Number of samples	36
Number of features	1 944
Total frequency	608 362

Рис. 8: Сводка по таблице ASV




Рис. 9: Распределение частот по образцам (слева) и по ASV (справа)

36 образцов, 1944 ASV, суммарно 608 362 прочтения. Частота на образец: от 4809 до 43 518, медиана 14 908. Частота на ASV: медиана 66, максимум 48 911, среднее 313. Распределение скошенное - чуть-чуть доминантов и хвост редких вариантов.

Задача 4. Почему хватает классификатора на V4

```
qiime feature-classifier classify-sklearn \  
  --i-classifier 2022.10.backbone.v4.nb.sklearn-1.4.2.qza \  
  --i-reads qza/soil_rep_seq.qza \  
  --o-classification qza/soil_taxonomy.qza \  
  --p-n-jobs 16
```

Праймеры подбирали под V4-V5, но мы работаем только с прямым прочтением. Оно стартует от 515F, после обрезки `trim-left 25` и `trunc-len 200` покрывает примерно позиции 540-715 по нумерации кишечной палочк. То есть целиком лежит внутри V4 (он занимает примерно 515-806) и до V5 просто не дотягивается. Так что V5 мы не анализируем потому что его в наших данных просто нет.

Задача 5. Кто живёт в почве и что с ними делает керосин

```
qiime taxa barplot \
  --i-table qza/soil_ASV_table.qza \
  --i-taxonomy qza/soil_taxonomy.qza \
  --m-metadata-file soil_metadata_full.tsv \
  --o-visualization qzv/soil_taxonomy_barplot.qzv
```




Рис. 10: Состав сообществ на уровне класса (Level 3), образцы упорядочены по переменной level_and_time_point

Медианные доли основных классов в первой и последней временных точках:

Класс	k0_t1	k5_t1	k25_t1	k0_t4	k5_t4	k25_t4
Gammaproteobacteria	9,6	9,9	9,2	6,6	9,6	87,1
Acidobacteriae	18,6	17,8	18,7	48,3	46,7	1,2
Alphaproteobacteria	16,9	16,1	16,8	15,9	11,8	3,2
Actinomycetia	10,6	10,7	10,9	5,1	12,3	1,0
Thermoleophilia	7,4	7,2	8,9	3,6	1,8	2,9
Bacteroidia	5,0	5,5	3,6	3,0	0,1	0,1
Planctomycetia	5,2	5,3	5,5	2,4	2,1	0,3

Похожи ли образцы в первой временной точке? Да - на день 3 k0, k5 и k25 очень похожи: Gammaproteobacteria 9,6 - 9,9 - 9,2, Acidobacteriae 18,6 - 17,8 - 18,7, и так по всем основным классам. (Значит, почву по ёмкостям разложили однородно, и всё, что мы видим - следствие керосина)

Как меняется состав со временем? Тут по трём дозам сценарии совершенно разные.

Контроль k0 меняется, но спокойно: Acidobacteriae вырастают с 18,6 до 48,3 процента, остальные подтягиваются.

Слабое загрязнение k5 ведёт себя почти как контроль: к t4 Acidobacteriae 46,7 процента, то есть сообщество в целом вернулось к нормальной почвенной структуре. Пять граммов керосина на килограмм почва пережила

А вот k25 - полный разгром. К дню 360 Gammaproteobacteria занимают **87,1 процента** сообщества, Acidobacteriae схлопываются с 18,7 до 1,2 процента, от разнообразного почвенного сообщества осталась только одна культура.

Самые частые классы. В первой точке у всех трёх доз одинаково: Acidobacteriae (около 18 процентов), Alphaproteobacteria (около 17), Actinomycetia и Gammaproteobacteria (примерно по 10). В последней точке: у k0 и k5 на первом месте Acidobacteriae (48 и 47 процентов), у k25 - Gammaproteobacteria (87 процентов).

Самый частый род в загрязнённых образцах - *Paraburkholderia*. Динамика:

Род	k0_t1	k0_t4	k5_t2	k5_t3	k5_t4	k25_t2	k25_t3	k25_t4
<i>Paraburkholderia</i>	0,3	0,2	14,9	26,1	5,9	27,3	53,7	84,2
<i>Acidoferrum</i>	4,8	12,3	10,4	9,3	24,5	5,7	1,2	0,2
<i>Neuskia</i>	0,0	0,0	6,3	8,8	0,7	0,0	2,1	0,0

В контроле этого рода практически нет (0,2-0,3 процента), а в k25 к дню 360 он занимает 84 процента (87 процентов Gammaproteobacteria - это почти целиком он и есть).




Рис. 11: Состав сообществ на уровне рода (Level 6)

Ожидаемо ли это при загрязнении керосином? Наверное да. Керосин - это смесь алканов от C9 до C16, то есть внезапно свалившийся на сообщество источник углерода при том же количестве азота и фосфора. Соотношение элементов перекашивается, и выигрывают бактерюшки, которые умеют окислять углеводороды и быстро расти. Проигрывают бактерюшки вроде ацидобактерий, которые умеют жить в бедной среде.

Еще в интернете написано, что *Paraburkholderia* и родственные *Burkholderiaceae* регулярно находят в нефтезагрязнённых почвах, так что все логично.

Из интересного: в k5 *Paraburkholderia* взлетает до 26 процентов к дню 180, а потом падает до 5,9. То есть бактерюшка съела доступный керосин и уступила место обратно обычным жителям. Загрязнение переработано, сообщество пришло в норму, ура. А в k25 керосина хватило на весь год :(.

Филогенетическое дерево

```
qiime phylogeny align-to-tree-mafft-fasttree \
--i-sequences qza/soil_rep_seq.qza \
--o-alignment qza/aligned_soil_rep_seq.qza \
--o-masked-alignment qza/masked_aligned_soil_rep_seq.qza \
--o-tree qza/soil_unrooted_tree.qza \
--o-rooted-tree qza/soil_rooted_tree.qza
```

Плагин *empress* не входит в используемый контейнер QIIME 2 и не может быть в него доустановлен, поэтому дерево выгружено в текстовый формат и нарисовано отдельным скриптом на Biopython и matplotlib. (уже писала об этом в семинаре)



Рис. 12: Филогенетическое дерево

Разрежение

```
qiime diversity core-metrics-phylogenetic \
  --i-phylogeny qza/soil_rooted_tree.qza \
  --i-table qza/soil_ASV_table.qza \
  --p-sampling-depth 4809 \
  --m-metadata-file soil_metadata_full.tsv \
  --output-dir soil_core_metrics_results
```

Порог 4809 - это глубина самого маленького образца. При нём сохраняются все 36 образцов.

Задача 6. Как расходятся образцы

```
qiime diversity beta-group-significance \
  --i-distance-matrix soil_core_metrics_results/weighted_unifrac_distance_matrix.qza \
  --m-metadata-file soil_metadata_full.tsv \
  --m-metadata-column contamination_level \
  --p-method permanova --p-pairwise \
  --o-visualization qzv/soil_weighted_unifrac_significance.qzv
```




Рис. 13: PCoA по weighted UniFrac, цвет по уровню загрязнения, форма по времени отбора пробы




Рис. 14: Тот же график, цвет по времени отбора пробы

Первая ось забирает 56,45 процента дисперсии, вторая 24,93, третья 7,04. То есть

почти вся структура данных укладывается в две первые оси.

Похожи ли образцы в первой временной точке? Да. На раскраске по времени все точки d3 (синие) лежат одной плотной группой, независимо от того, сколько керосина налили.

Как меняется положение со временем? Образцы уезжают вдоль первой оси, и чем дальше по времени, тем дальше от стартовой точки: d3 справа, d90 в середине, d180 и d360 слева. На раскраске по дозе видно, кто именно уезжает: контроль k0 (красный) держится довольно компактно, k5 (оранжевый) уходит в сторону, а k25 (синий) улетает дальше всех.

Есть ли признаки восстановления? Тут ответ разный для двух доз, чуть-чуть уже писала выше.

Для k5 - да. К дню 360 оранжевые квадратики подтягиваются в сторону контроля, а состав по barplot к t4 практически повторяет контрольный (*Acidobacteriae* 46,7 против 48,3 процента у k0). Плюс *Paraburkholderia*, которая доминировала на t3, к t4 схлопывается с 26 до 6 процентов. Сообщество переварило керосин и вернулось к нормальной жизни.

Для k25 - нет. Синие квадратики к t4 оказываются максимально далеко от всего остального, никакого возврата не видно.




Рис. 15: PCoA по unweighted UniFrac, цвет по уровню загрязнения




Рис. 16: Unweighted UniFrac, цвет по времени

Unweighted UniFrac смотрит только на присутствие и отсутствие таксонов, weighted - ещё и на их обилия. Сравнение двух картинок показывает природу различий. По unweighted первая ось забирает всего 35,39 процента против 56,45 у weighted, вторая 12,16 против 24,93, и группы разделяются заметно хуже.

Вывод: основные различия между образцами - это пропорции, а не набор таксонов. Керосин не столько выкосил линии подчистую, сколько перетасовал, кого сколько. Многие ацидобактерии в k25 присутствуют, просто их доля упала с 18 процентов до одного, и на фоне 84 процентов буркхольдерий их уже не особо видно.

PERMANOVA results	
method name	PERMANOVA
test statistic name	pseudo-F
sample size	36
number of groups	3
test statistic	7.757459
p-value	0.001
number of permutations	999

Рис. 17: Результат PERMANOVA по weighted UniFrac

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
k0	k25	24	999	13.681759	0.001	0.003
	k5	24	999	5.756176	0.006	0.009
k5	k25	24	999	4.602901	0.010	0.010

Рис. 18: Попарные сравнения PERMANOVA

PERMANOVA подтверждает картинку: pseudo-F = 7,76, p = 0,001 при 999 перестановках, 36 образцов, 3 группы. Попарно:

Группа 1	Группа 2	pseudo- F	q
k0	k25	13,68	0,003
k0	k5	5,76	0,009
k5	k25	4,60	0,010

Все три пары значимы, и величины расставлены логично (сильнее всего различаются контроль и сильное загрязнение (13,68), слабее - контроль и слабое загрязнение (5,76)).




Рис. 19: Распределения расстояний weighted UniFrac

Задача 7. Как меняется разнообразие

```
qiime diversity alpha-group-significance \
--i-alpha-diversity soil_core_metrics_results/shannon_vector.qza \
--m-metadata-file soil_metadata_full.tsv \
--o-visualization soil_core_metrics_results/soil_shannon_significance.qzv
```




Рис. 20: Индекс Шеннона по комбинации доза и время

Медианы индекса Шеннона по всем двенадцати группам:

Доза	t1 (день 3)	t2 (день 90)	t3 (день 180)	t4 (день 360)
k0	8,99	8,88	8,69	8,27
k5	9,03	7,80	6,62	6,84
k25	8,89	7,63	5,67	2,97

Контроль k0 медленно сползает с 8,99 до 8,27. Небольшое, ровное снижение, так как почва в закрытой банке потихоньку беднеет.

Слабое загрязнение k5 падает с 9,03 до 6,62 к дню 180, а дальше разворачивается вверх - 6,84 на дне 360. Прибавка маленькая, но направление сменилось, и вместе с составом сообщества по barplot можно сказать, что сообщество идет к восстановлению.

Сильное загрязнение k25 валится вниз везде: 8,89, потом 7,63, потом 5,67 и в итоге 2,97. Никакого разворота, и похоже, что если бы эксперимент продолжили, стало бы ещё хуже.

Индекс Шеннона 2,97 для почвы - это очень мало, для сравнения: в первой точке было почти 9. Такое значение означает, что сообщество фактически схлопнулось до нескольких доминантов.




Рис. 21: Индекс Шеннона по уровню загрязнения




Рис. 22: Индекс Шеннона по времени отбора

Статистика (тест Краскела-Уоллиса):

Группировка	H	p
contamination_level	8,98	0,011
day_after_contamination	22,34	$5,5 \cdot 10^{-5}$
level_and_time_point	34,29	$3,2 \cdot 10^{-4}$
replica_number	0,005	0,998

Попарные сравнения по дозе:

Группа 1	Группа 2	H	q
k0	k25	6,75	0,028
k0	k5	4,81	0,042
k25	k5	2,08	0,149

Обе дозы значимо отличаются от контроля, а между собой k5 и k25 - нет. Это потому, что усреднение по всем четырём точкам смазывает картину: на t1 они одинаковые, а расходятся только к концу. По отдельным точкам разница между ними огромная (6,84 против 2,97 на t4), но такое сравнение уже не проходит по статистике.

Попарные сравнения по времени:

Группа 1	Группа 2	H	q
d3	d180	12,79	0,001
d3	d360	12,79	0,001
d3	d90	11,56	0,001
d90	d180	3,95	0,056
d180	d360	0,24	0,627

День 3 значимо отличается от всех остальных точек, а дальше соседние точки друг от друга уже не отличаются. Основной провал разнообразия происходит в первые три месяца, дальше процесс идёт медленнее.

Про полную таблицу попарных сравнений по level_and_time_point. Она содержит 66 строк (12 групп попарно), в отчёт такое вставлять бессмысленно, поэтому вот выводы, а не скриншот.

Итого

Слабое загрязнение (5 г/кг) почва переносит. Разнообразие падает примерно на два пункта индекса Шеннона к дню 180, но к дню 360 начинает расти обратно. В итоге состав сообщества возвращается к контрольному, а *Paraburkholderia* уходит с 26 процентов до 6.

Сильное загрязнение (25 г/кг) - разнообразие падает втрое, сообщество схлопывается до практически одной культуры бактериюшек *Paraburkholderia* на 84 процента, а ацидобактерии исчезают почти полностью. Признаков восстановления за год нет ни по альфа-, ни по бета-разнообразию, ни по составу.