

Отчёт по семинару. Метагеномика, данные mice

Шорина Анна

20 сентября 2026 г.

Что вообще делаем

Данные из работы Rosshart et al. (Cell, 2017). Germ-free мышам C57BL/6 пересаживали либо лабораторную микробиоту (LabR), либо микробиоту диких мышей (WildR), после чего смотрели, как это влияет на устойчивость к гриппу H1N1 и к колоректальному раку. Было: W - дикие мыши, L - лабораторные, WR - колонизированные диким сообществом, LR - колонизированные лабораторным. Всего 29 образцов. Секвенировали участок V4 гена 16S rRNA, Illumina MiSeq, paired-end 2 × 250.

Вся обработка в QIIME 2 2024.10 (контейнер `quay.io/qiime2/amplicon:2024.10` как кто-то писал в беседе).

Качество сырых данных

```
fastqc -t 8 -o fastqc $DATA/*.fq
multiqc fastqc -o multiqc
```




Рис. 1: MultiQC: Mean Quality Scores по всем файлам

Импорт и статистика сырых прочтений

```
qiime tools import \
  -type 'SampleData[PairedEndSequencesWithQuality]' \
  -input-path mice_manifest.tsv \
  -output-path qza/mice_reads.qza \
  -input-format PairedEndFastqManifestPhred33V2

qiime demux summarize \
  -i-data qza/mice_reads.qza \
  -o-visualization qzv/mice_reads.qzv
```




Рис. 2: Качество прямых и обратных прочтений

Forward держит верхний квартиль на 38 примерно до 200-й позиции, после 225 всё окончательно обваливается (там нижние усы падают к $Q \approx 2$). Reverse начинает портиться уже с 165-й и после 195 выглядит совсем печально. Отсюда и параметры обрезки.

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Рис. 3: Число прочтений по образцам

29 образцов, 134 672 пары прочтений. Минимум 2138, медиана 4918, максимум 6394, среднее 4643,9. Отношение максимума к минимуму всего ≈ 3

DADA2

```
qiime dada2 denoise-paired \
  -i-demultiplexed-seqs qza/mice_reads.qza \
  -p-trim-left-f 0 -p-trim-left-r 0 \
  -p-trunc-len-f 220 -p-trunc-len-r 180 \
  -p-n-threads 4 \
  -o-table qza/mice_ASV_table.qza \
```

```
-o-representative-sequences qza/mice_rep_seq.qza \
-o-denoising-stats qza/mice_reads.dada2.stats.qza
```

Почему trim-left нулевой. Проверила первые ряды напрямую: R1 начинается с TACGGAGGGTGC AAGCGTTAATCGG... , то есть сразу с V4-инсера, праймера 515F там нет. R2 тоже начинается не с 806R. Праймеры уже срезаны, резать нечего.

Почему trunc-len 220 и 180. Обе границы стоят до начала обвала качества. Проверка перекрытия: ампликон без праймеров ≈ 252 п.н., DADA2 требует минимум 12 нт перекрытия без мисматчей, значит нужно $\text{trunc}_f + \text{trunc}_r \geq 264$. У нас $220 + 180 = 400$, то есть перекрытие $400 - 252 = 148$ нт. Запас нормальный, так что обрезку можно было выбирать чисто по качеству, особо не смотря на слияние.

Ну и тут же дополнительная проверка, что ряды действительно парные: конец R1 читался как ...GTTGAGGCTCGAAAGCGTGGGGAGCAAAC, а обратный комплемент начала R2 давад то же самое.

sample-id #q2-types	input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	merged numeric	percentage of input merged numeric	non-chimeric numeric	percentage of input non-chimeric numeric
L1	3773	3178	84.23	3046	2710	71.83	2667	70.69
L2	3669	3027	82.5	2875	2537	69.15	2537	69.15
L3	5346	4558	85.26	4386	3692	69.06	3443	64.4
L4	3836	3086	80.45	2922	2563	66.81	2509	65.41
L5	3311	2668	80.58	2538	2193	66.23	2132	64.39
L6	4572	3728	81.54	3526	3145	68.79	3133	68.53
L7	4536	3747	82.61	3602	3196	70.46	3145	69.33
L8	3498	2763	78.99	2626	2395	68.47	2395	68.47
LR1	5047	4539	89.93	4372	3970	78.66	3959	78.44
LR2	6394	5715	89.38	5576	4913	76.84	4858	75.98
LR3	5753	5059	87.94	4823	4164	72.38	4164	72.38
LR4	6062	5332	87.96	5153	4554	75.12	4526	74.66
LR5	6056	5274	87.09	5126	4679	77.26	4679	77.26
LR6	5855	5117	87.4	4991	4514	77.1	4514	77.1
LR7	5191	4608	88.77	4438	4108	79.14	4108	79.14
W1	2138	1712	80.07	1589	1390	65.01	1354	63.33
W2	3714	2834	76.31	2683	2380	64.08	2314	62.3
W3	3211	2769	86.23	2648	2424	75.49	2289	71.29
W4	3619	2978	82.29	2818	2444	67.53	2421	66.9
W5	4301	3442	80.03	3243	2794	64.96	2678	62.26
W6	5016	3659	72.95	3443	3028	60.37	2977	59.35
W7	3501	2739	78.23	2631	2445	69.84	2309	65.95
WR1	4804	4170	86.8	3984	3529	73.46	3529	73.46
WR2	4918	4168	84.75	3958	3557	72.33	3557	72.33
WR3	5446	4758	87.37	4579	3819	70.12	3797	69.72
WR4	5206	4471	85.88	4253	3665	70.4	3665	70.4
WR5	5450	4595	84.31	4405	3874	71.08	3874	71.08
WR6	5414	4675	86.35	4516	3862	71.33	3830	70.74
WR7	5035	4416	87.71	4270	3860	76.66	3844	76.35

Рис. 4: Статистика фильтрации по этапам DADA2

По всем образцам суммарно: 134 672 на входе, 113 785 после фильтра (84,5 %), 109 000

после денойзинга, 96 404 после слияния (71,6 %) и 95 207 без химер (**70,7 %** от исходного).

Потери размазаны ровно, нигде нет провала: фильтр по качеству забирает 15 %, денойзинг 4 %, слияние 12 %, химеры всего 1,2 %.

У LR остаётся 72-79 %, у WR 70-76 %, у L 64-71 %, а у диких W всего 59-71 %. Худший образец - W6 (59,4 %), лучший - LR7 (79,1 %). У диких мышей в сообществе больше редких вариантов, которые труднее вытащить из шума.

Таблица ASV

```
qiime feature-table summarize \
  -i-table qza/mice_ASV_table.qza \
  -o-visualization qzv/mice_ASV_table.qzv \
  -m-sample-metadata-file mice_metadata.tsv

qiime feature-table tabulate-seqs \
  -i-data qza/mice_rep_seq.qza \
  -o-visualization qzv/mice_rep_seqs.qzv
```

Summary Statistic	Value
Number of samples	29
Number of features	505
Total frequency	95 207

Рис. 5: Сводка по таблице ASV




Рис. 6: Распределение частот по образцам (слева) и по ASV (справа)

29 образцов, 505 ASV, суммарно 95 207 прочтений. Глубина от 1354 (W1) до 4858 (LR2), медиана 3443. Частота ASV: медиана 48 при максимуме 5020 и среднем 188,5 - распределение сильно скошено, видно длинный хвост редких вариантов (гистограмма частот на ASV построена в лог шкале, иначе от неё был бы виден только один столбик у нуля).

Таксономия

```
qiime feature-classifier classify-sklearn \
-i-classifier 2022.10.backbone.v4.nb.sklearn-1.4.2.qza \
-p-n-jobs 8 \
-i-reads qza/mice_rep_seq.qza \
-o-classification qza/mice_taxonomy.qza

qiime taxa barplot \
-i-table qza/mice_ASV_table.qza \
-i-taxonomy qza/mice_taxonomy.qza \
-m-metadata-file mice_metadata.tsv \
-o-visualization qzv/mice_taxonomy_barplot.qzv
```

Классификатор - наивный байес из scikit-learn на частотах k -меров, для каждого ASV он считает апостериорные вероятности по таксонам и выдаёт самый глубокий уровень, где уверенность не ниже 0,7.




Рис. 7: Таксономический состав на уровне типа (Level 2), образцы отсортированы по группам

Медианные доли по группам на уровне типа:

Тип	W	L	WR	LR
Firmicutes_A	29,3	75,4	57,4	84,8
Bacteroidota	26,2	14,6	23,9	8,6
Campylobacterota	24,9	0,0	10,7	0,0
Proteobacteria	7,6	0,0	0,2	0,0
Desulfobacterota_I	5,3	0,0	2,7	0,0
Deferribacterota	0,1	5,1	2,4	3,1

Лабораторные мыши - это почти полностью Firmicutes_A (75 % у L, 85 % у LR), дикie более разнообразны, Firmicutes_A занимает примерно третью, и еще есть целые типы, которых в лаборатории нет вовсе: Campylobacterota (25 %), Proteobacteria, Desulfobacterota.

Теперь колонка WR. Germ-free мыши, получившие дикую микробиоту, видимо наследуют её набор таксонов (Campylobacterota есть (10,7 %), Desulfobacterota), но пропорции там свои: Firmicutes_A поднимаются до 57 %, то есть вдвое выше донора, а Proteobacteria практически исчезают (0,2 % против 7,6 % у W). То ксть переносится состав, но не структура, хозяин и условия содержания переделывают сообщество под себя.




Рис. 8: Таксономический состав на уровне рода (Level 6)

Филогенетическое дерево

```
qiime phylogeny align-to-tree-mafft-fasttree \
-i-sequences qza/mice_rep_seq.qza \
-o-alignment qza/aligned_mice_rep_seq.qza \
```

```
-o-masked-alignment qza/masked_aligned_mice_rep_seq.qza \
-o-tree qza/mice_unrooted_tree.qza \
-o-rooted-tree qza/mice_rooted_tree.qza
```

У меня не построилось дерево по презентации с семинара, потому что работала в готовом контейнере, а плагин empress не входит в него и не может быть в него доустановлен. Поэтому дерево визуализировано отдельным скриптом (его писал chatGPT :)).




Рис. 9: Филогенетическое дерево

Альфа-разнообразие

```
qiime diversity core-metrics-phylogenetic \
-i-phylogeny qza/mice_rooted_tree.qza \
-i-table qza/mice_ASV_table.qza \
-p-sampling-depth 1354 \
-m-metadata-file mice_metadata.tsv \
-output-dir mice_core_metrics_results

qiime diversity alpha-group-significance \
-i-alpha-diversity mice_core_metrics_results/shannon_vector.qza \
-m-metadata-file mice_metadata.tsv \
```

-o-visualization mice_core_metrics_results/mice_shannon_significance.qzv

Порог разрежения взят равным 1354 (это минимальная глубина образца (W1)), при таком пороге сохраняются все 29 образцов. Разрежение нужно потому что образец с 5000 прочтений богаче образца с 1500 просто потому, что его больше прочитали. Поэтому из каждого образца случайно берётся ровно N прочтений без возвращения.




Рис. 10: Индекс Шеннона по группам

Медианы индекса Шеннона: W - 4,69, L - 5,23, WR - 5,76, LR - 5,78.

Kruskal-Wallis (all groups)

	Result
H	20.449014778325107
p-value	0.00013699079691560474

Kruskal-Wallis (pairwise)

[Download CSV](#)

		H	p-value	q-value
Group 1	Group 2			
L (n=8)	LR (n=7)	9.763393	0.001780	0.005341
	W (n=7)	5.357143	0.020638	0.024765
	WR (n=7)	7.714286	0.005479	0.008218
LR (n=7)	W (n=7)	9.800000	0.001745	0.005341
	WR (n=7)	0.004082	0.949060	0.949060
W (n=7)	WR (n=7)	9.016327	0.002676	0.005352

Рис. 11: Тест Краскела-Уоллиса для индекса Шеннона

Краскел-Уоллис по всем группам: $H = 20,45$, $p = 1,4 \cdot 10^{-4}$. Попарно значимы почти все пары: L vs LR ($q = 0,005$), L vs W ($q = 0,025$), L vs WR ($q = 0,008$), LR vs W ($q = 0,005$), W vs WR ($q = 0,005$). Единственная пара, которая не различается вообще - это LR vs WR: $H = 0,004$, $q = 0,949$.

Видимо, у доноров разнообразие разное (W значимо ниже L), а у реципиентов оно одинаковое и при этом выше, чем у обоих доноров. То есть сам факт колонизации

мыши даёт прибавку к разнообразию независимо от того, чьё сообщество пересаживали.

Бета-разнообразие

```
qiime diversity beta-group-significance \  
-i-distance-matrix mice_core_metrics_results/weighted_unifrac_distance_matrix.qza \  
-m-metadata-file mice_metadata.tsv \  
-m-metadata-column group \  
-p-method permanova -p-pairwise \  
-o-visualization qzv/mice_weighted_unifrac_significance.qzv
```




Рис. 12: PCoA по weighted UniFrac

Первая ось даёт 63,35 % дисперсии и разделяет лабораторный и дикий профили: L и LR лежат слева, W и WR справа. Вторая ось (12,51 %) отделяет WR от W. Дикie образцы там лежат широко по правому краю графика, то есть между отдельными дикими мышами разброс огромный (в лесу у каждой мышки своя еда и окружение).

PERMANOVA по всем группам: $\text{pseudo-F} = 21,14$, $p = 0,001$ (29 образцов, 4 группы, 999 перестановок). Все попарные сравнения значимы, на картинке таблица с сайта, ниже - то же самое в латехе (а то плохо видно).

Pairwise permanova results

Download CSV

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
L	LR	15	999	5.751445	0.001	0.0012
	W	15	999	27.259733	0.001	0.0012
	WR	15	999	32.263756	0.001	0.0012
LR	W	14	999	24.500232	0.001	0.0012
	WR	14	999	27.162642	0.003	0.0030
W	WR	14	999	10.991739	0.001	0.0012

Рис. 13: Попарные результаты PERMANOVA по weighted UniFra

Группа 1	Группа 2	pseudo-F	q
L	LR	5,75	0,0012
W	WR	10,99	0,0012
LR	W	24,50	0,0012
L	W	27,26	0,0012
LR	WR	27,16	0,0030
L	WR	32,26	0,0012

Самая маленькая пара L vs LR (5,75), то есть перенос лабораторной микробиоты в germ-free мышь воспроизводит донора почти точно, на PCoA эти группы вообще лежат одним облаком. Пара W vs WR вдвое больше (10,99).

Также L vs WR (32,26) - самая далёкая пара вообще, дальше даже чем L vs W. Лабораторная мышь с лабораторной микробиотой и лабораторная мышь с дикой микробиотой оказываются максимально непохожи друг на друга




Рис. 14: Распределения расстояний weighted UniFrac до каждой группы

Боксплоты расстояний говорят то же самое: внутригрупповые расстояния самые маленькие (медиана около 0,09-0,10), ближайшие соседи для L - это LR (0,12), а самые дальние - W (0,37). Обратите внимание на ширину боксов у W: разброс от 0,21 до 0,46 против узкого 0,05-0,14 у лабораторных групп.




Рис. 15: PCoA по unweighted UniFrac.

Unweighted UniFrac учитывает только присутствие и отсутствие таксонов, weighted - ещё и обилия, поэтому сравнение двух метрик показывает природу различий. По unweighted первая ось забирает 43,42 % против 63,35 % у weighted, вторая - 15,07 %. Расстановка групп та же, но различия слабее.

Вывод тот же самфй - при трансплантации состав переносится хорошо, а пропорции - нет.

Итого

Четыре группы различаются и по составу, и по разнообразию, все статистики значимы. Лабораторная микробиота переносится в germ-free мышь почти без потерь (L vs LR, $\text{pseudo-}F = 5,75$), дикая - заметно хуже (W vs WR, 10,99). Набор таксонов наследуется, пропорции переделываются хозяином, а отдельные роды вроде *Escherichia* не приживаются вовсе. Индекс Шеннона при этом у обеих колонизированных групп одинаков и выше, чем у доноров, то есть альфа-разнообразие ловит эффект самой колонизации, но не ловит, чьё именно сообщество пересадили. Различать группы здесь умеет только бета-разнообразие.