

Задание 1

Для анализа я выбрала ген алкогольдегидрогеназы (ADH, класс III / ADH5). Хочется верить, что фермент сопровождает эволюцию организмов в их взаимодействии с этанолом (что уже делает его интереснее, чем какие-нибудь абстрактные белки).

В качестве исходной последовательности была выбрана человеческая: Homo sapiens, NP-000662.3

Далее с помощью BLAST были найдены гомологичные последовательности у других организмов (рис. 1).

RID

YETX25UN014

Search expires on 04-22 20:03 pm

Download All

Program

BLASTP

Citation

Database

nr

See details

Query ID

AAA51596.1

Description

alcohol dehydrogenase [Homo sapiens]

Molecule type

amino acid

Query Length

374

Other reports

Distance tree of results

Multiple alignment

MSA viewer

Organism

only top 20 will appear

exclude

Type common name, binomial, taxid or group name

Add organism

Percent Identity

to

E value

to

Query Coverage

to

Filter

Reset

Compare these results against the new Clustered nr database

BLAST

Descriptions

Graphic Summary

Alignments

Taxonomy

Sequences producing significant alignments

Download

Select columns

Show

100

select all

7 sequences selected

GenPept

Graphics

Distance tree of results

Multiple alignment

MSA Viewer

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	alcohol dehydrogenase class-3 [Homo sapiens]	Homo sapiens	760	760	100%	0.0	100.00%	374	NP_000662.3
☐	Chain A, Alcohol dehydrogenase class-3 [Homo sapiens]	Homo sapiens	760	760	100%	0.0	100.00%	375	8GV3_A
☐	Chain A, Glutathione-dependent formaldehyde dehydrogenase [Homo sapiens]	Homo sapiens	758	758	100%	0.0	100.00%	373	1M6H_A
☐	alcohol dehydrogenase 5 (class III), chi polypeptide [Homo sapiens]	Homo sapiens	758	758	100%	0.0	99.73%	374	AAV38636.1
☐	Chain A, Alcohol dehydrogenase class-3 [Homo sapiens]	Homo sapiens	758	758	100%	0.0	100.00%	374	3QJ5_A
☐	ADH5 [Homo sapiens]	Homo sapiens	757	757	100%	0.0	99.73%	374	CAG38730.1
☒	ADH5 isoform 1 [Pan troglodytes]	Pan troglodytes	756	756	100%	0.0	99.47%	374	PNI56580.1
☐	Chain A, Alcohol dehydrogenase class III chi chain [Homo sapiens]	Homo sapiens	754	754	100%	0.0	99.73%	373	2FZW_A
☐	alcohol dehydrogenase class III [Homo sapiens]	Homo sapiens	754	754	100%	0.0	99.47%	392	AAA51597.1
☐	alcohol dehydrogenase 5 (class III), chi polypeptide, isoform CRA_b [Homo sapiens]	Homo sapiens	746	746	98%	0.0	100.00%	395	EAX06085.1
☒	alcohol dehydrogenase class-3 [Sus scrofa]	Sus scrofa	745	745	100%	0.0	96.52%	385	NP_001231762.1
☐	alcohol dehydrogenase 5 [Sus scrofa]	Sus scrofa	743	743	100%	0.0	96.52%	374	AKV89671.1
☒	alcohol dehydrogenase class-3 [Canis lupus familiaris]	Canis lupus fami...	735	735	100%	0.0	94.92%	374	NP_001239084.1
☒	alcohol dehydrogenase class-3 [Bos taurus]	Bos taurus	734	734	100%	0.0	94.92%	374	NP_001029421.1
☐	rcADH5, partial [Pan troglodytes]	Pan troglodytes	714	714	98%	0.0	95.38%	368	ABB92442.1
☐	hCG17981 [Homo sapiens]	Homo sapiens	713	713	99%	0.0	95.93%	369	FAW88504.1
☒	RecName: Full=Alcohol dehydrogenase class-3; AltName: Full=Alcohol dehydrogenase 5; AltName: Full=Alc...	Equus caballus	711	711	100%	0.0	94.92%	374	P19854.2
☐	Adh5, protein, partial [Rattus norvegicus]	Rattus norvegicus	702	702	100%	0.0	94.39%	379	AAH83724.1
☒	alcohol dehydrogenase class-3 [Rattus norvegicus]	Rattus norvegicus	701	701	100%	0.0	94.39%	374	NP_001119592.1

Рис. 1: Задание 1 - параметры blast

Группа	Вид
Млекопитающие	<i>Homo sapiens</i> (человек)
	<i>Pan troglodytes</i> (шимпанзе)
	<i>Sus scrofa</i> (свинья)
	<i>Equus caballus</i> (лошадь)
	<i>Canis lupus familiaris</i> (собака)
	<i>Bos taurus</i> (корова)
	<i>Rattus norvegicus</i> (крыса)
	<i>Mus musculus</i> (мышь)
	<i>Gallus gallus</i> (курица)
	<i>Taeniopygia guttata</i> (амадина)
Птицы	<i>Anas platyrhynchos</i> (утка)
	<i>Anolis carolinensis</i> (ящерица)
	<i>Xenopus laevis</i> (лягушка)
Рептилии, амфибии и рыбы	<i>Oreochromis niloticus</i> (рыбка)
	<i>Danio rerio</i> (еще рыбка из предыдущего дз)

Команда для переименования строк в fasta-файле:

```
from Bio import SeqIO

with open(r"bioinf\ADH_ren.fasta", "w") as out:
    for record in SeqIO.parse(r"bioinf\ADH.fasta", "fasta"):
        desc = record.description
        organism = desc.split("[")[1].replace("]", "").replace(" ", "_")
        record.id = f"{organism}_{record.id}"
        record.description = ""
        SeqIO.write(record, out, "fasta")
```

Задание 2

Измененный fasta-файл был загружен в MEGA, для выравнивания использовался алгоритм MUSCLE.




Рис. 2: Задание 2 - выравнивание

Задание 3

Лучшая модель молекулярной эволюции оказалась WAG+I (рис. 3) - учитывает вероятности замен аминокислот и наличие консервативных (инвариантных) позиций, она используется дальше в Maximum Likelihood (ML) дереве (рис. 4).

Results

File Edit View Windows Help

TXT

Table. Maximum Likelihood analysis of substitution models

Model	Parameters	BIC	AICc	lnL	(+I)	(+G)	f(A)	f(R)	f(N)	f(D)	f(C)	f(Q)	f(E)	f(G)	f(H)	f(I)	f(L)	f(K)	f(M)	f(F)
WAG+I	28	5208.975	5024.484	-2484.092	0.60	n/a	0.087	0.044	0.039	0.057	0.019	0.037	0.058	0.083	0.024	0.048	0.086	0.062	0.020	0.038
WAG+G+I	29	5212.291	5021.222	-2481.450	0.54	2.77	0.087	0.044	0.039	0.057	0.019	0.037	0.058	0.083	0.024	0.048	0.086	0.062	0.020	0.038
JTT+I	28	5220.568	5036.077	-2489.888	0.60	n/a	0.077	0.051	0.043	0.051	0.020	0.041	0.062	0.075	0.023	0.053	0.091	0.060	0.023	0.041
JTT+G+I	29	5223.470	5032.401	-2487.039	0.55	2.60	0.077	0.051	0.043	0.051	0.020	0.041	0.062	0.075	0.023	0.053	0.091	0.060	0.023	0.041
LG+I	28	5227.269	5042.778	-2493.239	0.60	n/a	0.079	0.056	0.042	0.053	0.013	0.041	0.072	0.057	0.022	0.062	0.099	0.065	0.023	0.042
LG+G+I	29	5228.471	5037.402	-2489.540	0.54	2.25	0.079	0.056	0.042	0.053	0.013	0.041	0.072	0.057	0.022	0.062	0.099	0.065	0.023	0.042
Dayhoff+I	28	5235.289	5050.798	-2497.249	0.60	n/a	0.087	0.041	0.040	0.047	0.034	0.038	0.050	0.089	0.034	0.037	0.085	0.081	0.015	0.040
Dayhoff+G+I	29	5237.584	5046.515	-2494.096	0.56	2.76	0.087	0.041	0.040	0.047	0.034	0.038	0.050	0.089	0.034	0.037	0.085	0.081	0.015	0.040
cpREV+G+I	29	5260.278	5069.209	-2505.443	0.50	1.81	0.076	0.062	0.041	0.037	0.009	0.038	0.050	0.084	0.025	0.081	0.101	0.050	0.022	0.051
cpREV+I	28	5262.707	5078.216	-2510.958	0.58	n/a	0.076	0.062	0.041	0.037	0.009	0.038	0.050	0.084	0.025	0.081	0.101	0.050	0.022	0.051
rtREV+I	28	5272.455	5087.964	-2515.832	0.59	n/a	0.065	0.045	0.038	0.042	0.011	0.061	0.061	0.064	0.027	0.068	0.102	0.075	0.015	0.029
rtREV+G+I	29	5273.862	5082.793	-2512.235	0.53	2.30	0.065	0.045	0.038	0.042	0.011	0.061	0.061	0.064	0.027	0.068	0.102	0.075	0.015	0.029
LG+I+F	47	5313.048	5003.700	-2454.431	0.59	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
LG+G+I+F	48	5315.066	4999.155	-2451.141	0.54	2.57	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
WAG+I+F	47	5317.113	5007.766	-2456.464	0.59	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
JTT+I+F	47	5319.947	5010.600	-2457.881	0.60	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
WAG+G+I+F	48	5321.115	5005.204	-2454.165	0.55	3.09	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
JTT+G+I+F	48	5322.417	5006.506	-2454.816	0.55	2.68	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
cpREV+I+F	47	5323.387	5014.039	-2459.601	0.59	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
cpREV+G+I+F	48	5326.378	5010.467	-2456.796	0.54	2.72	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
rtREV+I+F	47	5328.936	5019.589	-2462.375	0.59	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
rtREV+G+I+F	48	5330.572	5014.661	-2458.893	0.54	2.49	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042
Dayhoff+I+F	47	5351.417	5042.070	-2473.616	0.60	n/a	0.094	0.025	0.023	0.041	0.040	0.022	0.068	0.112	0.020	0.071	0.058	0.087	0.022	0.042

Рис. 3: Задание 3 - поиск лучшей модели

ALIGN DATA MODELS DISTANCE DIVERSITY PHYLOGENY USER TREE ANCESTORS

M12: Analysis Preferences

Likelihood Phylogeny Reconstruction

Option	Setting
ANALYSIS	
Statistical Method	Maximum Likelihood
PHYLOGENY TEST	
Test of Phylogeny	Standard Bootstrap (slow)
Bootstrap Replicates	100
SUBSTITUTION MODEL	
Substitutions Type	Amino acid
Model/Method	WAG model
RATES AND PATTERNS	
Rates among Sites	Has Invariant Sites (I)
DATA SUBSET TO USE	

Рис. 4: Задание 3 - параметры для ML

Задание 4

Различия между методами: Maximum Likelihood учитывает модель эволюции и является более точным, но чувствителен к качеству данных, Neighbor-Joining и UPGMA основаны на расстояниях и дают более стабильные, но упрощенные результаты.




Рис. 5: Дерево ML




Рис. 6: Дерево NJ

Деревья NJ и UPGMA показали более высокие значения bootstrap (около 90–100), в дереве ML встречаются более низкие значения (50–70), то есть некоторые ветви определены не так уверенно.




Рис. 7: Дерево UPGMA

В целом, филогенетика по АДН работает, деревья отражают реальные эволюционные отношения: человек и шимпанзе всегда вместе, мышь и крыса — тоже, рыбы образуют отдельный кластер, птицы группируются. Из странного - млекопитающие не всегда собираются в одну группу, положение ящерицы и лягушки немного плавают. Идеально-го рыбы-амфибии-рептилии-птицы-млекопитающие не получилось. Наверное, различия можно объяснить неравномерностью жволюции, разные виды шли к трезвости разными путями :)

Наиболее адекватным по биологическому смыслу выглядит дерево NJ, UPGMA тоже кажется аккуратным.

Чтобы улучшить анализ, наверное, стоит рассмотреть вопрос шире и добавить больше генов, можно также попробовать увеличить bootstrap (например, до 1000).